


# 《数值分析》 第五章

- 矩阵基础知识
- Gauss 消去法
- 矩阵三角分解
- 向量与矩阵范数
- 误差分析

# 线性方程组直接解法



$$Ax = b$$

$$A \in R^{n \times n}, b \in R^n$$

- 自然科学和工程计算中, 很多问题最终都需要求解一个线性代数方程组
- 目前使用的数值解法:
  - (1) **直接法**: 适合低阶方程组或某些特殊大型稀疏方程组
  - (2) **迭代法**: 解大型稀疏方程组的主流算法

在本章中, 我们总是假定  $A$  是  $n$  阶非奇异方阵

## 5.1 预备知识

- 向量与矩阵：定义，基本运算，行列式
- 特征值与特征向量，特征多项式，特征方程，矩阵相似

$$Ax = \lambda x \quad (\lambda \in C, x \in C^n, x \neq 0)$$

- 矩阵的谱： $\sigma(A) = \{ A \text{ 的所有特征值} \}$

- 矩阵的谱半径： $\rho(A) = \max_{\lambda \in \sigma(A)} \{ |\lambda| \}$

- 矩阵的迹： $\text{tr}(A) = a_{11} + a_{22} + \cdots + a_{nn}$

# 矩阵基本性质

- $A^T$  与  $A$  有相同的特征值，但特征向量不同
- $A^{-1}$  的特征值与特征向量

$$Ax = \lambda x \Leftrightarrow A^{-1}x = \lambda^{-1}x$$

- 矩阵的迹与特征值

$$\text{tr}(A) = \lambda_1 + \lambda_2 + \cdots + \lambda_n$$

- 矩阵行列式与特征值

$$\det(A) = \lambda_1 \lambda_2 \cdots \lambda_n$$

- 相似矩阵的特征值与特征向量

# 一些特殊矩阵

- 对角矩阵、三角矩阵、三对角矩阵
- 对称矩阵、Hermite对称矩阵、对称正定矩阵
- 正交矩阵、酉矩阵
- 初等置换阵、置换阵（排列阵）
- 上 Hessenberg 矩阵

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & & a_{1n} \\ a_{21} & a_{22} & a_{23} & \cdots & a_{2n} \\ & a_{32} & a_{33} & & a_{3n} \\ & & \ddots & \ddots & \vdots \\ & & & a_{n,n-1} & a_{nn} \end{bmatrix}$$

$$a_{ij} = 0 \text{ for } i > j + 1$$

# 一些重要性质

## 定理 1

(解的存在唯一性, 教材 141 页)

## 定理 2

(对称正定矩阵的性质, 教材 141 页)

## 定理 3

(对称矩阵正定的充分条件, 教材 141 页)

## 定理 4

(Jordan 标准型, 教材 142 页)

## 5.2 Gauss 消去法

例：用直接法解线性方程组

$$\begin{cases} x_1 - 2x_2 + 2x_3 = -2 \\ 2x_1 - 3x_2 - 3x_3 = 4 \\ 4x_1 + x_2 + 6x_3 = 3 \end{cases}$$

解：

$$(A, b) = \left[ \begin{array}{ccc|c} 1 & -2 & 2 & -2 \\ 2 & -3 & -3 & 4 \\ 4 & 1 & 6 & 3 \end{array} \right] \longrightarrow \left[ \begin{array}{ccc|c} 1 & -2 & 2 & -2 \\ \color{red}{0} & \color{blue}{1} & \color{blue}{-7} & \color{blue}{8} \\ \color{red}{0} & \color{blue}{9} & \color{blue}{-2} & \color{blue}{11} \end{array} \right]$$

$$\left[ \begin{array}{ccc|c} 1 & -2 & 2 & -2 \\ \color{red}{0} & \color{blue}{1} & \color{blue}{-7} & \color{blue}{8} \\ \color{red}{0} & \color{red}{0} & \color{magenta}{61} & \color{magenta}{-61} \end{array} \right] \longrightarrow \begin{cases} x_3 = -1 \\ x_2 = 8 + 7x_3 = 1 \\ x_1 = -2 + 2x_2 - 2x_3 = 2 \end{cases}$$


# Gauss 消去法

考虑  $n$  阶线性方程组：

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\ \vdots \quad \quad \quad \vdots \quad \quad \quad \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n \end{cases} \xrightarrow{\text{矩阵形式}} Ax = b$$

- 高斯消去法的主要思路：

将系数矩阵  $A$  化为上三角矩阵，然后回代求解





记  $A^{(1)} = (a_{ij}^{(1)})_{n \times n} = A$ ,  $b^{(1)} = \begin{pmatrix} b_1^{(1)} \\ \vdots \\ b_n^{(1)} \end{pmatrix} = b$  , 即  $a_{ij}^{(1)} = a_{ij}$ ,  $b_i^{(1)} = b_i$

## 第 1 步：消第 1 列

设  $a_{11}^{(1)} \neq 0$  , 计算  $m_{i1} = a_{i1}^{(1)} / a_{11}^{(1)}$  ( $i = 2, \dots, n$ )

依次将增广矩阵的 第  $i$  行 -  $m_{i1} \times$  第 1 行, 得

$$A^{(2)} = \left( \begin{array}{cccc|c} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} & b_1^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} & b_2^{(2)} \\ & \vdots & \ddots & \vdots & \vdots \\ & a_{n2}^{(2)} & \cdots & a_{nn}^{(2)} & b_n^{(2)} \end{array} \right) \quad \text{其中} \quad \begin{cases} a_{ij}^{(2)} = a_{ij}^{(1)} - m_{i1} a_{1j}^{(1)} \\ b_i^{(2)} = b_i^{(1)} - m_{i1} b_1^{(1)} \end{cases}$$

( $i, j = 2, \dots, n$ )

## 第 2 步：消第 2 列

设  $a_{22}^{(2)} \neq 0$ ，计算  $m_{i2} = a_{i2}^{(2)} / a_{22}^{(2)}$  ( $i = 3, \dots, n$ )

依次将  $A^{(2)}$  的第  $i$  行  $-m_{i2} \times$  第 2 行，得

$$A^{(3)} = \left[ \begin{array}{ccccc|c} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1n}^{(1)} & b_1^{(1)} \\ & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2n}^{(2)} & b_2^{(2)} \\ & & a_{33}^{(3)} & \cdots & a_{3n}^{(3)} & b_3^{(3)} \\ & & \vdots & \ddots & \vdots & \vdots \\ & & a_{n3}^{(3)} & \cdots & a_{nn}^{(3)} & b_n^{(3)} \end{array} \right]$$

其中  $\begin{cases} a_{ij}^{(3)} = a_{ij}^{(2)} - m_{i2} a_{2j}^{(2)} \\ b_i^{(3)} = b_i^{(2)} - m_{i2} b_2^{(2)} \end{cases} \quad (i, j = 3, \dots, n)$

依此类推，第  $k-1$  步 后可得

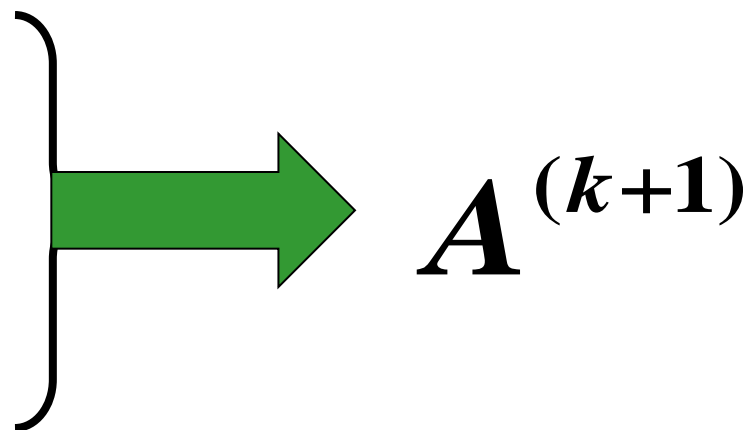
$$A^{(k)} = \begin{bmatrix} a_{11}^{(1)} & \cdots & a_{1k}^{(1)} & \cdots & a_{1n}^{(1)} \\ & \ddots & \vdots & & \vdots \\ & & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} \\ & & \vdots & \ddots & \vdots \\ & & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} \end{bmatrix}$$

### 第 $k$ 步：消第 $k$ 列

设  $a_{kk}^{(k)} \neq 0$

先计算：  $m_{ik} = a_{ik}^{(k)} / a_{kk}^{(k)}$   
(  $i = k+1, \dots, n$  )

再计算：  $a_{ij}^{(k+1)} = a_{ij}^{(k)} - m_{ik} a_{kj}^{(k)}$   
 $b_i^{(k+1)} = b_i^{(k)} - m_{ik} b_k^{(k)}$   
(  $i = k+1, \dots, n$  )


$$A^{(k+1)}$$

## 第 $n-1$ 步后

$$\begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} \\ & & \ddots & \vdots \\ & & & a_{nn}^{(n)} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1^{(1)} \\ b_2^{(2)} \\ \vdots \\ b_n^{(n)} \end{bmatrix} \longleftrightarrow A^{(n)} x = b^{(n)}$$

## 回代求解:

$$x_n = b_n^{(n)} / a_{nn}^{(n)}$$

$$x_i = \left( b_i^{(i)} - \sum_{j=i+1}^n a_{ij}^{(i)} x_j \right) / a_{ii}^{(i)} \quad (i = n-1, \dots, 1)$$

# 几点注记

- 主元:  $a_{ii}^{(i)} \quad (i = 1, 2, \dots, n)$
- Gauss 消去法能进行到底的条件: 主元全不为 0

定理:  $a_{ii}^{(i)} \neq 0 \quad (i=1, 2, \dots, n)$  的充要条件是  $A$  的顺序主子式不为零, 即

$$D_1 = a_{11} \neq 0, \quad D_i = \begin{vmatrix} a_{11} & \cdots & a_{1i} \\ \vdots & \ddots & \vdots \\ a_{i1} & \cdots & a_{ii} \end{vmatrix} \neq 0, \quad i = 1, 2, \dots, n$$

推论:  $a_{11}^{(1)} = D_1, \quad a_{ii}^{(i)} = D_i / D_{i-1}, \quad i = 2, \dots, n$

# 运算量

## ● 乘除运算 的次数

第  $k$  步: 消第  $k$  列

计算  $m_{ik} = a_{ik}^{(k)} / a_{kk}^{(k)} \quad (i = k+1, \dots, n)$

计算  $a_{ij}^{(k+1)} = a_{ij}^{(k)} - m_{ik} a_{kj}^{(k)} \quad (i = k+1, \dots, n)$

$b_i^{(k+1)} = b_i^{(k)} - m_{ik} b_k^{(k)}$

回代求解: 
$$\begin{cases} x_n = b_n^{(n)} / a_{nn}^{(n)} \\ x_i = (b_i^{(i)} - \sum_{j=i+1}^n a_{ij}^{(i)} x_j) / a_{ii}^{(i)} \quad (i = n-1, \dots, 2, 1) \end{cases}$$

$n - k$  次

$(n - k)^2$  次

$n - k$  次

$n(n+1)/2$  次

Gauss 消去法的乘除运算量为:  $\frac{n^3}{3} + n^2 - \frac{n}{3}$

## ● 加减运算 的次数

$$\frac{n^3}{3} + \frac{n^2}{2} - \frac{5n}{6}$$

## 5.2.2 LU 分解

- 换个角度看 Gauss 消去法

 矩阵的三角分解过程

矩阵分解，即将一个较复杂的矩阵分解成若干结构简单的矩阵的乘积，是矩阵计算中的一个很重要的技术

# LU 分解

将 Gauss 消去过程中第  $k-1$  步消元后的系数矩阵记为：

$$A^{(k)} = \begin{bmatrix} a_{11}^{(1)} & \cdots & a_{1k}^{(1)} & \cdots & a_{1n}^{(1)} \\ & \ddots & \vdots & & \vdots \\ & & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} \\ & & \vdots & \ddots & \vdots \\ & & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} \end{bmatrix} \quad (k = 1, \dots, n-1)$$

则  $A^{(k)}$  与  $A^{(k+1)}$  之间的关系式可以表示为：

$$A^{(k+1)} = L_k A^{(k)}$$

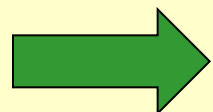
其中：

$$L_k = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -m_{k+1,k} & 1 & \\ & & \vdots & & \ddots \\ & & -m_{n,k} & & 1 \end{bmatrix}$$

$$m_{ik} = a_{ik}^{(k)} / a_{kk}^{(k)} \\ (i = k + 1, \dots, n)$$



于是有:  $A^{(n)} = L_{n-1} \cdots L_2 L_1 A^{(1)}$



$$A = A^{(1)} = (L_{n-1} \cdots L_2 L_1)^{-1} A^{(n)}$$

容易验证:

$$L_k^{-1} = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & m_{k+1,k} & 1 & \\ & & \vdots & & \ddots \\ & & m_{n,k} & & & 1 \end{bmatrix} \quad (k = 1, \dots, n-1)$$

且  $L_1^{-1} L_2^{-1} \cdots L_{n-1}^{-1} = \begin{bmatrix} 1 & & & & \\ m_{2,1} & 1 & & & \\ m_{3,1} & m_{3,2} & 1 & & \\ m_{4,1} & m_{4,2} & m_{4,3} & \ddots & \\ \vdots & \vdots & \vdots & & 1 \\ m_{n,1} & m_{n,2} & m_{n,3} & \cdots & m_{n,n-1} & 1 \end{bmatrix}$

记：  $L = L_1^{-1}L_2^{-1}\cdots L_n^{-1}$ ，  $U = A^{(n)}$ ， 则

$$\boxed{A = LU} \longrightarrow \text{LU 分解}$$

其中：  $L$  --- 单位下三角矩阵，  $U$  --- 非奇异上三角矩阵

注： LU分解中要求  $L$  是单位下三角，  $U$  是非奇异上三角！

# LU 分解存在唯一性

$LU$  分解存在  $\longleftrightarrow$  高斯消去法不被中断



所有顺序主子式不为零  $\longleftrightarrow a_{kk}^{(k)} \neq 0$

**定理：**  $A$  存在唯一的  $LU$  分解的充要条件是  $A$  的所有顺序主子式都不为零。

## 5.2.3 列主元 Gauss 消去法

- 为什么要选主元？

Gauss 消去法有效的条件是 **主元全不为零**！

例：解线性方程组 
$$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

- 列主元 Gauss 消去法

在第  $k$  步消元时，在第  $k$  列的剩余部分选取主元

① 先选取列主元：  $|a_{i_k k}^{(k)}| = \max_{k \leq i \leq n} \{|a_{ik}^{(k)}|\} \neq 0$

② if  $i_k \neq k$  then 交换第  $k$  行和第  $i_k$  行

③ 消元

# 列主元 Gauss 消去法

## 算法 (列主元Gauss消去法)

**for**  $k=1$  **to**  $n-1$

$$|a_{i_k k}^{(k)}| = \max_{k \leq i \leq n} \{|a_{ik}^{(k)}|\} \neq 0$$

**if**  $a_{i_k k}^{(k)} = 0$  **then stop**

**if**  $i_k \neq k$  **then swap**  $k$ -th and  $i_k$ -th row (including  $b$ )

**for**  $i=k+1$  **to**  $n$

$$m_{ik} = a_{ik} / a_{kk}$$

$$a_{ij} = a_{ij} - m_{ik} a_{kj}, \quad j = k + 1, k + 2, \dots, n$$

$$b_i = b_i - m_{ik} b_k$$

**end**

**end**

$$x_n = b_n / a_n, \quad x_i = \left( b_i - \sum_{j=i+1}^n a_{ij} x_j \right) / a_{ii}, \quad i = n-1, \dots, 2, 1$$

# PLU 分解

- 列主元 Gauss 消去法对应的矩阵分解为 **PLU 分解**

**定理：**若  $A$  非奇异，则存在排列矩阵  $P$ ，使得

$$PA = LU$$

其中  $L$  为单位下三角矩阵， $U$  为上三角矩阵

- 列主元 Gauss 消去法比普通 Gauss 消去法要多一些比较运算，但比普通高斯消去法稳定
- 列主元 Gauss 消去法是目前直接法的首选算法

# 全主元Gauss消去法

- 全主元高斯消去法

第  $k$  步消元时，在剩余的  $n-k$  阶子矩阵中选取主元

① 先选取全主元： $|a_{i_k j_k}^{(k)}| = \max_{k \leq i, j \leq n} \{|a_{ij}^{(k)}|\} \neq 0$

② if  $i_k \neq k$  then 交换第  $k$  行和第  $i_k$  行  
if  $j_k \neq k$  then 交换第  $k$  列和第  $j_k$  列

③ 消元

- 列交换改变了  $x_i$  的顺序，须记录交换次序，解完后再换回来
- 全主元高斯消去法具有更好的稳定性，但很费时，在实际计算中很少使用

## 5.3 LU 三角分解

- 什么是矩阵的三角分解
  - 将一个矩阵分解成结构简单的三角矩阵的乘积
- Gauss 消去法对应的矩阵三角分解

矩阵的  $LU$  分解

$$A = LU$$

矩阵的  $LDR$  分解

$$A = LDR$$

克洛脱 (Crout) 分解

$$A = \tilde{L}\tilde{U}$$



# LU 分解

## ● 利用矩阵乘法直接计算 LU 分解 —— 待定系数法

$$\begin{bmatrix} 1 & & & \\ l_{21} & 1 & & \\ \vdots & & \ddots & \\ l_{n1} & \cdots & l_{n,n-1} & 1 \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ & u_{22} & & u_{2n} \\ & & \ddots & \vdots \\ & & & u_{nn} \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & & a_{2n} \\ \vdots & & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

$$L \times U = A$$

□ 比较等式两边的**第一行**得:  $u_{1j} = a_{1j}$  ( $j = 1, \dots, n$ ) U 的第一行

比较等式两边的**第一列**得:  $l_{i1} = a_{i1}/u_{11}$  ( $i = 2, \dots, n$ ) L 的第一列

□ 比较等式两边的**第二行**得:  $u_{2j} = a_{2j} - l_{21}u_{1j}$  ( $j = 2, \dots, n$ ) U 的第二行

比较等式两边的**第二列**得:  $l_{i2} = (a_{i2} - l_{i1}u_{12})/u_{22}$  ( $i = 3, \dots, n$ ) L 的第二列

# 计算 LU 分解

第  $k$  步：此时  $U$  的前  $k-1$  行和  $L$  的前  $k-1$  列已经求出

比较等式两边的第  $k$  行得：

$$u_{kj} = a_{kj} - \left( l_{k1}u_{1j} + \cdots + l_{k,k-1}u_{k-1,j} \right) = a_{kj} - \sum_{i=1}^{k-1} l_{ki}u_{ij} \quad (j = k, \dots, n)$$

比较等式两边的第  $k$  列得：

$$l_{ik} = \left( a_{ik} - l_{i1}u_{1k} - \cdots - l_{i,k-1}u_{k-1,k} \right) / u_{kk} = \left( a_{ik} - \sum_{j=1}^{i-1} l_{ij}u_{jk} \right) / u_{kk} \quad (i = k+1, \dots, n)$$

直到第  $n$  步，便可求出矩阵  $L$  和  $U$  的所有元素。

● 这种计算 LU 分解的方法也称为 Doolittle 分解

# LU 分解

算法：(LU 分解)

for  $k = 1$  to  $n$

运算量：  $(n^3 - n)/3$

$$a_{kj} \leftarrow u_{kj} = a_{kj} - \sum_{i=1}^{k-1} l_{ki} u_{ij}, \quad j = k, \dots, n$$

$$a_{ik} \leftarrow l_{ik} = \left( a_{ik} - \sum_{j=1}^{k-1} l_{ij} u_{jk} \right) / u_{kk}, \quad i = k+1, \dots, n$$

end

为了节省存储空间，通常用  $A$  的绝对下三角部分来存放  $L$  (对角线元素无需存储)，用  $A$  的上三角部分来存放  $U$

# LU 分解算法

算法：(LU 分解求解方程组)

**% 先计算 LU 分解**

**for  $k = 1$  to  $n$**

$$a_{kj} = a_{kj} - \sum_{i=1}^{k-1} a_{ki} a_{ij}, \quad j = k, k+1, \dots, n$$

$$a_{ik} = \frac{1}{a_{kk}} \left( a_{ik} - \sum_{j=1}^{k-1} a_{ij} a_{jk} \right), \quad i = k+1, k+2, \dots, n$$

**end**

**% 解三角方程组  $Ly = b$  和  $Ux = y$**

$$y_1 = b_1, \quad y_i = b_i - \sum_{k=1}^{i-1} a_{ik} y_k, \quad i = 2, 3, \dots, n$$

$$x_n = y_n, \quad x_i = \frac{1}{a_{ii}} \left( y_i - \sum_{k=i+1}^n a_{ik} x_k \right), \quad i = n-1, n-2, \dots, 1$$

# PLU 分解

## ● 列主元 Gauss 消去法 —— PLU 分解 $PA = LU$

for  $k = 1$  to  $n$

$$a_{ik} = a_{ik} - \sum_{j=1}^{k-1} a_{ij} a_{jk}, \quad i = k, k+1, \dots, n$$

$$a_{i_k k} = \max_{k \leq i \leq n} |a_{ik}|, \quad \text{Ip}(k) \leftrightarrow \text{Ip}(i_k)$$

$$a_{kj} \leftrightarrow a_{i_k j}, \quad j = 1, 2, \dots, n$$

$$a_{ik} = a_{ik} / a_{kk}, \quad i = k+1, \dots, n$$

$$a_{kj} = a_{kj} - \sum_{i=1}^{k-1} a_{ki} a_{ij}, \quad j = k+1, \dots, n$$

end

● 此算法可以用于计算矩阵的行列式和逆

# PLU 分解算法

算法：(PLU 分解求解方程组)

for  $k = 1$  to  $n$

$$a_{ik} = a_{ik} - \sum_{j=1}^{k-1} a_{ij} a_{jk}, \quad i = k, k+1, \dots, n$$

$$a_{i_k k} = \max_{k \leq i \leq n} |a_{ik}|, \quad \text{Ip}(k) \leftrightarrow \text{Ip}(i_k)$$

$$a_{kj} \leftrightarrow a_{i_k j}, \quad j = 1, 2, \dots, n$$

$$a_{ik} = a_{ik} / a_{kk}, \quad i = k, k+1, \dots, n$$

$$a_{kj} = a_{kj} - \sum_{i=1}^{k-1} a_{ki} a_{ij}, \quad j = k, k+1, \dots, n$$

end

% 解三角方程组  $Ly = Pb$  和  $Ux = y$

$$y_1 = b_{\text{Ip}(1)}, \quad y_i = b_{\text{Ip}(i)} - \sum_{k=1}^{i-1} a_{ik} y_k, \quad i = 2, 3, \dots, n$$

$$x_n = y_n, \quad x_i = \frac{1}{a_{ii}} \left( y_i - \sum_{k=i+1}^n a_{ik} x_k \right), \quad i = n-1, n-2, \dots, 1$$

## 5.3.2 Cholesky 分解

### ● 对称正定矩阵的三角分解 —— Cholesky 分解

**定理：（Cholesky分解）** 若  $A$  对称正定，则  $A$  可唯一分解为

$$A = LL^T$$

其中  $L$  为下三角实矩阵，且对角元素都大于 0

**定理：** 设  $A$  是对称矩阵，若  $A$  的所有顺序主子式都不为 0，则  $A$  可唯一分解为


$$A = LDL^T$$

其中  $L$  为单位下三角阵， $D$  为对角矩阵

# 计算 Cholesky 分解

## ● 如何计算 Cholesky 分解 —— 待定系数法

$$\begin{bmatrix} l_{11} & & & \\ l_{21} & l_{22} & & \\ \vdots & & \ddots & \\ l_{n1} & \cdots & l_{n,n-1} & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & \cdots & l_{n1} \\ & l_{22} & & l_{n2} \\ & & \ddots & \vdots \\ & & & l_{nn} \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & & a_{2n} \\ \vdots & & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$



$$a_{ij} = \sum_{k=1}^n l_{ik} l_{jk} = \sum_{k=1}^{j-1} l_{ik} l_{jk} + l_{jj} l_{ij} \quad (i \geq j)$$

$$j = 1, 2, \dots, n, \quad i = j, j+1, \dots, n$$



# Cholesky 分解算法

算法 : (Cholesky 分解)

for  $j = 1$  to  $n$

$$l_{jj} = \left( a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2 \right)^{\frac{1}{2}},$$

$$l_{ij} = \frac{1}{l_{jj}} \left( a_{ij} - \sum_{k=1}^{j-1} l_{ik} l_{jk} \right), \quad i = j+1, \dots, n$$

end

# 平方根法

- 用 Cholesky 分解求解线性方程组 —— 平方根法

$$Ax = b$$

$A$  对称正定

算法：(解对称正定线性方程组的平方根法)

先计算  $A$  的 Cholesky 分解

然后解方程： $Ly = b$  和  $L^T x = y$

$$y_1 = b_1 / l_{11}, \quad y_i = \left( b_i - \sum_{k=1}^{i-1} l_{ik} y_k \right) / l_{ii}, \quad i = 2, 3, \dots, n$$


$$x_n = y_n / l_{nn}, \quad x_i = \left( y_i - \sum_{k=i+1}^n l_{ki} x_k \right) / l_{ii}$$

$i = n-1, \dots, 2, 1$

# 改进的 Cholesky 分解

- 改进的 Cholesky 分解

$$A = LDL^T = \begin{bmatrix} 1 & & & \\ l_{21} & 1 & & \\ \vdots & & \ddots & \\ l_{n1} & \cdots & l_{n,n-1} & 1 \end{bmatrix} \begin{bmatrix} d_1 & & & \\ & d_2 & & \\ & & \ddots & \\ & & & d_n \end{bmatrix} \begin{bmatrix} 1 & l_{21} & \cdots & l_{n1} \\ & 1 & & l_{n2} \\ & & \ddots & \vdots \\ & & & 1 \end{bmatrix}$$



$$a_{ij} = \sum_{k=1}^n l_{ik} d_k l_{jk} = \sum_{k=1}^{j-1} l_{ik} d_k l_{jk} + l_{ij} d_j \quad (i \geq j)$$

$$j = 1, 2, \dots, n, \quad i = j, j+1, \dots, n$$

# 改进的 Cholesky 分解

算法：(改进的 Cholesky 分解)

for  $j = 1$  to  $n$

$$d_j = a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2 d_k ,$$

$$l_{ij} = \frac{1}{d_j} \left( a_{ij} - \sum_{k=1}^{j-1} l_{ik} d_k l_{jk} \right) , \quad i = j+1, \dots, n$$

end

- 优点：避免开方运算

# 改进的平方根法

- 改进的平方根法

$$Ax = b$$

$A$  对称正定

算法：（解对称正定线性方程组的改进的平方根法）

先计算 改进的 Cholesky 分解

然后解方程组：  $Ly = b$  和  $DL^Tx = y$

$$y_1 = b_1, \quad y_i = b_i - \sum_{k=1}^{i-1} l_{ik} y_k, \quad i = 2, 3, \dots, n$$

$$x_n = y_n / d_n, \quad x_i = y_i / d_i - \sum_{k=i+1}^n l_{ki} x_k, \\ i = n-1, \dots, 2, 1$$

## 5.3.3 三对角矩阵 LU 分解

- 对角占优的不可约三对角矩阵的 Crout 分解

$$\begin{bmatrix} b_1 & c_1 & & \\ a_1 & \ddots & \ddots & \\ & \ddots & \ddots & c_{n-1} \\ & & a_{n-1} & b_n \end{bmatrix} = \begin{bmatrix} \alpha_1 & & & \\ a_1 & \alpha_2 & & \\ & \ddots & \ddots & \\ & & a_{n-1} & \alpha_n \end{bmatrix} \begin{bmatrix} 1 & \beta_1 & & \\ & 1 & \ddots & \\ & & \ddots & \beta_{n-1} \\ & & & 1 \end{bmatrix}$$

- 计算过程

- (1) 第一步:  $\alpha_1 = b_1, \beta_1 = c_1/\alpha_1 = c_1/b_1$
- (2) 第二步:  $\alpha_i = b_i - a_{i-1}\beta_{i-1}, \beta_i = c_i/\alpha_i \quad i = 2, 3, \dots, n-1$
- (3) 第三步:  $\alpha_n = b_n - a_{n-1}\beta_{n-1}$

- 为了编程方便, 这里  $a$  的下标从 1 开始 (教材是从 2 开始)
- 关于对角占优、不可约等性质, 会在第六章详细讲述

# 追赶法

## ● 三对角线性方程组的求解 —— 追赶法

$$Ax = f$$

$A$  三对角矩阵（对角占优不可约）

算法：（追赶法）

$$\beta_1 = c_1/b_1, \quad \beta_i = c_i / (b_i - a_{i-1}\beta_{i-1}) \quad \leftarrow \text{追}$$

$i = 2, 3, \dots, n-1$

$$y_1 = f_1/b_1, \quad y_i = (f_i - a_{i-1}y_{i-1}) / (b_i - a_{i-1}\beta_{i-1}) \quad \leftarrow \text{追}$$

$i = 2, 3, \dots, n$

$$x_n = y_n, \quad x_i = y_i - \beta_i x_{i+1} \quad \leftarrow \text{赶}$$

$i = n-1, \dots, 2, 1$

● 运算量：约  $5n+3n$

实际计算中 $Ax=f$ 的阶数往往很高,应注意 $A$ 的存贮技术.

已知数据只用4个一维数组就可存完.即 $\{a_i\}, \{b_i\}, \{c_i\}, \{f_i\}$ 各占一个一维数组,  $\{\alpha_i\}$ 和 $\{\beta_i\}$ 可存放在 $\{b_i\}, \{c_i\}$ 的位置,  $\{y_i\}$ 和 $\{x_i\}$ 则可放在 $\{f_i\}$ 的位置,整个运算可在4个一维数组中运行.

追赶法的计算量很小,只是 $5(n-1)$ 次乘除法.追赶法的计算也不要选主元素.



## 5.4 向量和矩阵范数

- 向量内积（数量积）

- 定义与性质、Cauchy-Schwarz不等式
- 导出范数（欧氏范数）

- 向量范数

**定义：** 设函数  $f: R^n \rightarrow R$ ，若  $f$  满足

(1)  $f(x) \geq 0$ ， $\forall x \in R^n$ ，等号当且仅当  $x = 0$  时成立（正定性）

(2)  $f(\alpha x) = |\alpha| \cdot f(x)$ ， $\forall x \in R^n, \forall \alpha \in R$ （齐次性）

(3)  $f(x+y) \leq f(x) + f(y)$ （三角不等式）

则称  $f$  为  $R^n$  上的（向量）范数，通常记为  $\|\cdot\|$

# 常见向量范数

## ● $R^n$ 空间上常见的向量范数

● 1-范数:  $\|x\|_1 = \sum_{i=1}^n |x_i| = |x_1| + |x_2| + \cdots + |x_n|$

● 2-范数:  $\|x\|_2 = \left( \sum_{i=1}^n x_i^2 \right)^{\frac{1}{2}} = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$

●  $p$ -范数:  $\|x\|_p = \left( \sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$

●  $\infty$ -范数（有时也称最大范数）:  $\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$

# 范数性质

## ● 范数的性质

### (1) 连续性

**定理：** 设  $f$  是  $R^n$  上的任一向量范数，则  $f$  关于  $x$  的每个分量连续。

### (2) 等价性

**定理：** 设  $\|\cdot\|_s$  和  $\|\cdot\|_t$  是  $R^n$  上的任意两个范数，则存在常数  $c_1$  和  $c_2$ ，使得对任意的  $x \in R^n$  有

$$c_1 \|x\|_s \leq \|x\|_t \leq c_2 \|x\|_s$$

**定理** （范数的等价性） 对任何向量  $x \in R^n$  ,有

$$(1) \quad \|X\|_2 \leq \|X\|_1 \leq \sqrt{n} \|X\|_2$$

$$(2) \quad \|X\|_\infty \leq \|X\|_1 \leq n \|X\|_\infty$$




$$(3) \quad \|X\|_\infty \leq \|X\|_2 \leq \sqrt{n} \|X\|_\infty$$

**证明** (2) :  $\|x\|_1 = |x_1| + |x_2| + \cdots + |x_n|$

$$\max_{1 \leq k \leq n} |x_k| \leq \|x\|_1 \leq n \times \max_{1 \leq k \leq n} |x_k|$$

所以  $\|x\|_\infty \leq \|x\|_1 \leq n \|x\|_\infty$

例. 范数意义下的单位向量:  $\mathbf{X}=[x_1, x_2]^T$



$$\|\mathbf{X}\|_1 = |x_1| + |x_2|$$

$$\|\mathbf{X}\|_2 = \sqrt{x_1^2 + x_2^2}$$

$$\|\mathbf{X}\|_\infty = \max\{|x_1|, |x_2|\}$$

# 范数性质

## (3) Cauchy-Schwarz 不等式

定理：  $|(x, y)| \leq \|x\|_2 \cdot \|y\|_2$

## (4) 向量序列的收敛性

定义： 设  $\{x^{(k)}\}$  是  $R^n$  中的一个向量序列， 其中

$$x^{(k)} = [x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)}]^T$$

如果  $\lim_{k \rightarrow \infty} x_i^{(k)} = x_i$ ， 则称  $x^{(k)}$  收敛到  $x$ ， 记为  $\lim_{k \rightarrow \infty} x^{(k)} = x$

定理： 设  $\|\cdot\|$  是  $R^n$  上的任意一个向量范数， 则

$$\lim_{k \rightarrow \infty} x^{(k)} = \tilde{x} \iff \lim_{k \rightarrow \infty} \|x^{(k)} - \tilde{x}\| = 0$$

# 矩阵范数

## ● 矩阵范数

**定义：** 设函数  $f: R^{n \times n} \rightarrow R$ ，若  $f$  满足

(1)  $f(A) \geq 0$ ， $\forall A \in R^{n \times n}$ ，且  $f(A) = 0 \Leftrightarrow A = 0$  （正定性）

(2)  $f(\alpha A) = |\alpha| \cdot f(A)$ ， $\forall A \in R^n, \forall \alpha \in R$  （齐次性）

(3)  $f(A+B) \leq f(A) + f(B)$  （三角不等式）

(4)  $f(AB) \leq f(A)f(B)$  （相容性）

则称  $f$  为  $R^{n \times n}$  上的（矩阵）范数，通常记为  $\|\cdot\|$

# 常见矩阵范数

## ● 常见的矩阵范数

(1) **F-范数 (Frobenious 范数):**  $\|A\|_F = \left( \sum_{i=1}^n \sum_{j=1}^n a_{ij}^2 \right)^{\frac{1}{2}}$

(2) **算子范数 (从属范数、诱导范数)**

$$\|A\| = \sup_{\substack{x \in R^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|$$

其中  $\|\cdot\|$  是  $R^n$  上的任意一个向量范数

注：教材上的定义不太严谨  $\|A\| = \max_{\|x\| \neq 0} \frac{\|Ax\|}{\|x\|}$



# 算子范数

- 常见的算子范数

① 1-范数（列范数）  $\longleftrightarrow \|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$

② 2-范数（谱范数）  $\longleftrightarrow \|A\|_2 = \sqrt{\rho(A^T A)}$

③  $\infty$ -范数（行范数）  $\longleftrightarrow \|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$

# 算子范数举例

例： 设  $A = \begin{pmatrix} 1 & -2 \\ -3 & 4 \end{pmatrix}$  计算  $\|A\|_1, \|A\|_2, \|A\|_\infty, \|A\|_F$

# 矩阵范数性质

## ● 矩阵范数的性质

(1) 连续性：设  $f$  是  $R^{n \times n}$  上的任一矩阵范数，则  $f$  关于  $A$  的每个分量是连续的。

(2) 等价性：设  $\|\cdot\|_s$  和  $\|\cdot\|_t$  是  $R^{n \times n}$  上的任意两个矩阵范数，则存在常数  $c_1$  和  $c_2$ ，使得对任意的  $A \in R^{n \times n}$  有

$$c_1 \|A\|_s \leq \|A\|_t \leq c_2 \|A\|_s$$

(3) 若  $A$  是对称矩阵，则  $\|A\|_2 = \rho(A)$

# 算子范数性质

## ● 算子范数的性质

**定理：** 设  $\|\cdot\|$  是任一算子范数，则  $\rho(A) \leq \|A\|$

**注：** 该性质对 F-范数也成立。

**定理：** 对任意  $\varepsilon > 0$ ，总存在一算子范数  $\|\cdot\|_\varepsilon$ ，使得

$$\|A\|_\varepsilon \leq \rho(A) + \varepsilon$$

# 算子范数性质

## ● 算子范数的性质

**定理：** 设  $\|\cdot\|$  是  $R^n$  上的任一向量范数，其对应的算子范数也记为  $\|\cdot\|$ ，则有

$$\|Ax\| \leq \|A\| \cdot \|x\|$$

**证明：** 直接由算子范数定义可得

 该性质就是矩阵范数与向量范数的相容性

**定理：** 设  $\|\cdot\|$  是任一算子范数，若  $\|B\| < 1$ ，则  $I \pm B$  非奇异，且

$$\|(I \pm B)^{-1}\| \leq \frac{1}{1 - \|B\|}$$

## 5.5 误差分析

### 引例. Hilbert矩阵的病态性



*Hilbert*

$$A = \begin{bmatrix} 1 & 1/2 & 1/3 & 1/4 \\ 1/2 & 1/3 & 1/4 & 1/5 \\ 1/3 & 1/4 & 1/5 & 1/6 \\ 1/4 & 1/5 & 1/6 & 1/7 \end{bmatrix}$$

$$b = \begin{bmatrix} 1 \\ 2 \\ 1.41 \\ 2 \end{bmatrix}$$

方程组  $Ax = b$  的解为  $x$

方程组  $Ax = b_1$  的解为  $x_1$

$$b_1 = \begin{bmatrix} 1 \\ 2 \\ 1.42 \\ 2 \end{bmatrix}$$

数据计算结果

$$x - x_1 = [-2.4 \quad 27.0 \quad -64.8 \quad 42.0]^T$$

## ● 什么是病态矩阵

**定义：**考虑线性方程组  $Ax=b$ ，如果  $A$  或  $b$  的微小变化会导致解的巨大变化，则称此线性方程组是病态的，并称矩阵  $A$  是病态的，反之则是良态的。

**例：**

$$\begin{bmatrix} 1 & 1 \\ 1 & 1.0001 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} \quad \longrightarrow \quad \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$
$$\begin{bmatrix} 1 & 1 \\ 1 & 1.0001 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 2.0001 \end{bmatrix} \quad \longrightarrow \quad \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

**结论：**（1）的常数项  $b$  的第二个分量只有  $1/1000$  的微小变化，方程组的解变化却很大。

**定义** 若矩阵 $A$ 或常数项 $b$ 的微小变化引起方程组 $Ax=b$ 的解的巨大变化，则称此方程组为**病态方程组**， $A$ 为**病态矩阵**（相对方程组而言）；否则称方程组为**良态方程组**， $A$ 为**良态矩阵**。

研究方程组中 $A$ 或 $b$ 的微小误差对解的影响的分析称“**扰动分析**”。

设 $Ax=b$ 的扰动方程组为 $(A + \delta A)(x + \delta x) = b + \delta b$ ，  
其中， $\delta A$ 叫 $A$ 的**扰动矩阵**，  
 $\delta x$ 和 $\delta b$ 叫 $x$ 和 $b$ 的**扰动向量**。



设 $Ax=b$ 的扰动方程组为 $(A+\delta A)(x+\delta x)=b+\delta b$ ，下面进行扰动分析：

(1)  $\delta A=0$ ，则 $A(x+\delta x)=b+\delta b$ ，减去 $Ax=b$ ，得

$A\delta x=\delta b$ ，故 $\delta x=A^{-1}\delta b$ ，即 $\|\delta x\|\leq\|A^{-1}\|\|\delta b\|$ ，又由 $Ax=b$ ，有 $\|b\|\leq\|A\|\|x\|$ ，所以

$$\frac{\|\delta x\|}{\|x\|} \leq \|A^{-1}\| \cdot \|A\| \cdot \frac{\|\delta b\|}{\|b\|}$$

(2)  $\delta b=0$ ，则 $(A+\delta A)(x+\delta x)=b$ ，同理可得

$$\frac{\|\delta x\|}{\|x+\delta x\|} \leq \|A^{-1}\| \cdot \|A\| \cdot \frac{\|\delta A\|}{\|A\|}$$

# 矩阵条件数

## ● 如何判别矩阵是否病态 —— 矩阵的条件数

定义：设  $A$  非奇异，则称

$$\text{Cond}(A)_\nu = \|A^{-1}\|_\nu \|A\|_\nu$$

为  $A$  的条件数，其中  $\nu$  是 1, 2 或  $\infty$ 。

# 矩阵条件数

**定理：**考虑线性方程组  $Ax=b$ ，设  $b$  是精确的， $A$  有微小的变化  $\delta A$ ，此时的解为  $x + \delta x$ 。假定  $\|A^{-1}\|\|\delta A\| < 1$ ，则

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\|\|A\| \frac{\|\delta A\|}{\|A\|}}{1 - \|A^{-1}\|\|A\| \frac{\|\delta A\|}{\|A\|}}$$

● 当  $\delta A$  充分小时，不等式右端约为  $\|A^{-1}\|\|A\| \frac{\|\delta A\|}{\|A\|}$

- 通常，当  $A$  的条件数较大时，就称  $A$  就是病态的
- 一般来说，条件数越大，病态越严重，此时就越难用一般方法求得线性方程组的比较精确的解。

# 矩阵条件数

- 条件数与范数有关，常用的有无穷范数和2-范数

$$\text{Cond}(A)_{\infty} = \|A^{-1}\|_{\infty} \|A\|_{\infty}$$

$$\text{Cond}(A)_2 = \|A^{-1}\|_2 \|A\|_2$$

注： $\text{Cond}(A)_2$  称为谱条件数，当  $A$  对称时有

$$\text{Cond}(A)_2 = \frac{\max_{1 \leq i \leq n} |\lambda_i|}{\min_{1 \leq i \leq n} |\lambda_i|}$$

# 条件数性质

## 条件数的性质

- $\text{Cond}(A) \geq 1$
- $\text{Cond}(\alpha A) = \text{Cond}(A)$ , 其中  $\alpha$  为任意非零实数
- 若  $R$  是正交矩阵, 则  $\text{Cond}(R)_2 = 1$
- 若  $R$  是正交矩阵, 则对任意非奇异矩阵  $A$ , 有  $\text{Cond}(AR)_2 = \text{Cond}(RA)_2 = \text{Cond}(A)_2$
- 条件数小, 扰动引起的解的相对误差一定小;  
条件数大, 扰动引起的解的误差可能很大 (条件数与所取的范数有关, 最常用的是  $\|\cdot\|_\infty$  和  $\|\cdot\|_2$ )

**注：**一般判断矩阵是否病态，并不计算 $A^{-1}$ ，而由经验得出。

- 行列式很大或很小（如某些行、列近似相关）；
- 元素间相差大数量级，且无规则；
- 主元消去过程中出现小主元；
- 特征值相差大数量级。

**例**  $A = \begin{pmatrix} 1 & 0.99 \\ 0.99 & 0.98 \end{pmatrix}$ ,  $\bar{b} = \begin{pmatrix} 1.99 \\ 1.97 \end{pmatrix}$  精确解为  $\bar{x} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ .

计算 $\text{cond}(A)_2$ 。

$$A^{-1} = \begin{pmatrix} -9800 & 9900 \\ 9900 & -10000 \end{pmatrix}$$

# 举例

例:  $A = \begin{bmatrix} 1 & 1 \\ 1 & 1.0001 \end{bmatrix}$  计算  $\text{Cond}(A)_\infty$  和  $\text{Cond}(A)_2$

解:  $A^{-1} = \begin{bmatrix} 10001 & -10000 \\ -10000 & 10000 \end{bmatrix}$

➡  $\text{Cond}(A)_\infty = \|A^{-1}\|_\infty \|A\|_\infty \approx 4 \times 10^4$

$A$  对称, 且  $\lambda(A) = \frac{2.0001 \pm \sqrt{2.0001^2 - 0.0004}}{2} > 0$

➡  $\text{Cond}(A)_2 = \lambda_{\max} / \lambda_{\min} \approx 4 \times 10^4$

# 举例

**例：** 计算  $\text{Cond}(H_k)_\infty$  其中  $H_k$  为  $k$  阶 Hilbert 矩阵

**解：**  $k=1$  时,  $\text{Cond}(H_1)_\infty=1$

$$k=2 \text{ 时, } H_2 = \begin{bmatrix} 1 & 1/2 \\ 1/2 & 1/3 \end{bmatrix}, H_2^{-1} = \begin{bmatrix} 4 & -6 \\ -6 & 12 \end{bmatrix}$$

  $\text{Cond}(H_2)_\infty=27$

$$k=3 \text{ 时, } H_3 = \begin{bmatrix} 1 & 1/2 & 1/3 \\ 1/2 & 1/3 & 1/4 \\ 1/3 & 1/4 & 1/5 \end{bmatrix}, H_3^{-1} = \begin{bmatrix} 9 & -36 & 30 \\ -36 & 192 & -180 \\ 30 & -180 & 180 \end{bmatrix}$$

  $\text{Cond}(H_3)_\infty=748$

$\text{Cond}(H_4)_\infty=28375, \text{Cond}(H_{10})_\infty=3.5 \times 10^{13}$



# 解的改善（了解）

(1) : 使用更高精度的数进行计算

(2) : 使用迭代法提高数值解的精度

$$x^{new} = x^{old} + \Delta x$$

其中  $\Delta x$  是  $A\Delta x = b - Ax^{old}$  的解。

# 总结

- **LU分解与Gauss消去法区别**
- **对称正定矩阵的Cholesky分解**
- **向量与矩阵范数**
- **误差分析（条件数）**