

# 《数值分析》第六章

- Jacobi迭代与Seidel迭代
- 超松弛(SOR)迭代算法
- 迭代矩阵与收敛性分析
- 共轭梯度法

## 6.1 迭代法基本概念

向量序列的收敛  
矩阵序列的收敛

# 向量序列的极限

**定义：** 设向量序列  $\{x^{(k)}\}_{k=0}^{\infty}$ ， $x^{(k)} = [x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)}]^T$ ，

若存在向量  $x = [x_1, x_2, \dots, x_n]^T$ ，使得

$$\lim_{k \rightarrow \infty} x_i^{(k)} = x_i \quad i = 1, 2, \dots, n$$

则称向量序列  $\{x^{(k)}\}_{k=0}^{\infty}$  收敛到  $x$ ，记作  $\lim_{k \rightarrow \infty} x^{(k)} = x$

- 每个分量组成的序列都收敛
- 称  $x$  是向量序列  $x^{(k)}$  的极限

$$\lim_{k \rightarrow \infty} x^{(k)} = x \quad \longleftrightarrow \quad \lim_{k \rightarrow \infty} \|x^{(k)} - x\| = 0$$

# 矩阵序列的极限

**定义：** 设矩阵序列  $A_k = [a_{ij}^{(k)}]_{n \times n}$ ，若存在矩阵  $A = [a_{ij}]_{n \times n}$ ，使得

$$\lim_{k \rightarrow \infty} a_{ij}^{(k)} = a_{ij} \quad i, j = 1, 2, \dots, n$$

则称矩阵序列  $\{A_k\}$  收敛到  $A$ ，记作  $\lim_{k \rightarrow \infty} A_k = A$

**例：** 设  $|a| < 1$ ，考察下面矩阵序列的极限

$$A = \begin{bmatrix} a & 1 \\ 0 & a \end{bmatrix}, A^2 = \begin{bmatrix} a^2 & 2a \\ 0 & a^2 \end{bmatrix}, \dots, A^k = \begin{bmatrix} a^k & ka^{k-1} \\ 0 & a^k \end{bmatrix}, \dots$$

# 矩阵极限判断

**定理:**  $\lim_{k \rightarrow \infty} A_k = A \iff \lim_{k \rightarrow \infty} \|A_k - A\| = 0$

(其中  $\|\cdot\|$  为任一算子范数)

$$\lim_{k \rightarrow \infty} A_k = 0 \iff \lim_{k \rightarrow \infty} \|A_k\| = 0$$

$$\lim_{k \rightarrow \infty} A^k = 0 \iff \lim_{k \rightarrow \infty} \|A^k\| = 0$$

# 矩阵极限判断

**定理:**  $\lim_{k \rightarrow \infty} A_k = 0 \iff \lim_{k \rightarrow \infty} A_k x = 0, \quad \forall x \in \mathbf{R}^n$

**定理:**  $\|B\| < 1 \implies \lim_{k \rightarrow \infty} B^k = 0$

# 矩阵极限判断

定理:  $\lim_{k \rightarrow \infty} B^k = 0 \iff \rho(B) < 1$

定理:  $\lim_{k \rightarrow \infty} B^k = 0 \iff$  存在某算子范数  $\|\cdot\|_{\varepsilon}$ , 使得  
 $\|B\|_{\varepsilon} < 1$

定理:  $\rho(B) = \lim_{k \rightarrow \infty} \|B^k\|^{\frac{1}{k}}$  (其中  $\|\cdot\|$  为任一矩阵范数)

## 6.1.3 线性方程组迭代法

- 直接法的缺点

- 运算量大，不适合大规模的线性方程组求解
- 无法充分利用系数矩阵的稀疏性

- 迭代法

从一个初始向量出发，按照一定的迭代格式，构造出一个趋向于真解的向量序列。

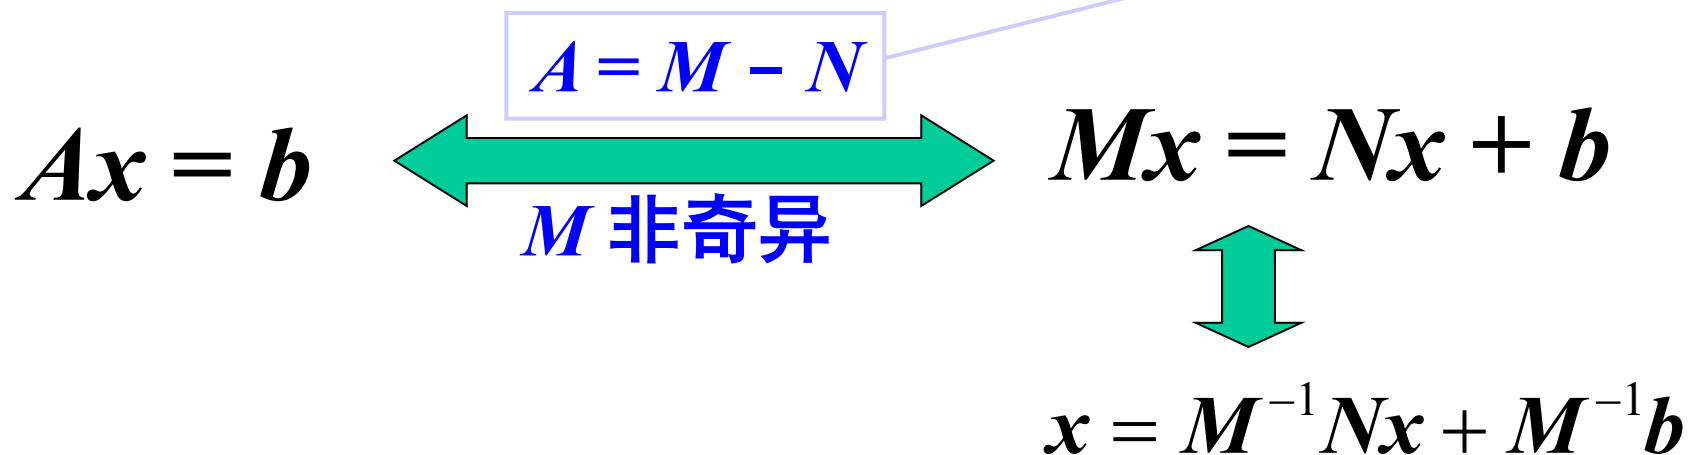
- 只需存储系数矩阵中的非零元素
- 运算量不超过  $O(kn^2)$ ，其中  $k$  为迭代步数

迭代法是目前求解大规模线性方程组的主要方法



# 迭代法的构造

- 矩阵分裂迭代法基本思想



给定一个初始向量  $x^{(0)}$ , 可得 迭代格式

$$x^{(k+1)} = Bx^{(k)} + f \quad k = 0, 1, 2, \dots$$

其中  $B = M^{-1}N$  称为迭代矩阵

# 矩阵分裂迭代法

$$\mathbf{x}^{(k+1)} = B\mathbf{x}^{(k)} + \mathbf{f} \quad k = 0, 1, 2, \dots$$

**定义：**若  $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)}$  存在，则称该迭代法收敛，否则称为发散

**性质：**若  $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}_*$ ，则  $\mathbf{x}_*$  为原方程组  $A\mathbf{x} = \mathbf{b}$  的解

$$A\mathbf{x}_* = \mathbf{b} \Leftrightarrow \mathbf{x}_* = B\mathbf{x}_* + \mathbf{f}$$

**注：**这里用  $\mathbf{x}_*$  表示真解，教材上用  $\mathbf{x}^*$

# 迭代法的收敛性

$$\boldsymbol{x}^{(k+1)} = B\boldsymbol{x}^{(k)} + \boldsymbol{f}$$

**定理：** 对任意初始向量  $\boldsymbol{x}^{(0)}$ ，上述迭代格式收敛的充要条件是

$$\rho(B) < 1$$

**定理：** 若存在算子范数  $\|\cdot\|$ ，使得  $\|B\| < 1$ ，对任意的初始向量  $\boldsymbol{x}^{(0)}$ ，上述迭代格式收敛。

**例：** 考虑迭代法  $\boldsymbol{x}^{(k+1)} = B\boldsymbol{x}^{(k)} + \boldsymbol{f}$  的收敛性，其中

$$B = \begin{bmatrix} 0.9 & 0 \\ 0.3 & 0.8 \end{bmatrix}$$

# 收敛性分析

$$A x = b \Rightarrow (M - N) x = b \Rightarrow M x = N x + b$$

$$\text{计算格式: } x^{(k+1)} = B x^{(k)} + f \quad (B = M^{-1}N)$$

设方程组的精确解为  $x^*$ , 则有

$$x^* = B x^* + f \quad \Rightarrow$$

$$x^{(k+1)} - x^* = B(x^{(k)} - x^*)$$

$$\text{记 } \varepsilon^{(k)} = x^{(k)} - x^* \quad (k = 0, 1, 2, 3, \dots)$$

$$\text{则有 } \varepsilon^{(k+1)} = B \varepsilon^{(k)}$$

$$\varepsilon^{(k)} = B \varepsilon^{(k-1)} \quad (k = 1, 2, 3, \dots)$$

**命题** 若 $\|B\|<1$ ,则迭代法  $x^{(k+1)} = B x^{(k)} + f$  收敛

**证:** 由 $\varepsilon^{(k)} = B \varepsilon^{(k-1)}$ ,得

$$\|\varepsilon^{(k)}\| \leq \|B\| \|\varepsilon^{(k-1)}\| \quad (k = 1, 2, 3, \dots)$$

$$\Rightarrow \|\varepsilon^{(k)}\| \leq \|B\|^k \|\varepsilon^{(0)}\|$$

$$\|B\| < 1 \quad \Rightarrow \quad \lim_{k \rightarrow \infty} \|\varepsilon^{(k)}\| \leq \lim_{k \rightarrow \infty} \|B\|^k \|\varepsilon^{(0)}\| = 0$$

所以

$$\lim_{k \rightarrow \infty} \varepsilon^{(k)} = 0$$

# 迭代法的收敛性

$$\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$$

$$\mathbf{B} = \mathbf{M}^{-1}\mathbf{N}$$

**定理：**若存在算子范数  $\|\cdot\|$ ，使得  $\|\mathbf{B}\| = q < 1$ ，则

(1) 迭代法收敛

$$(2) \quad \|\mathbf{x}^{(k)} - \mathbf{x}_*\| \leq q^k \|\mathbf{x}^{(0)} - \mathbf{x}_*\|$$

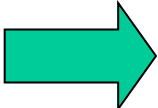
$$(3) \quad \|\mathbf{x}^{(k)} - \mathbf{x}_*\| \leq \frac{q}{1-q} \|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|$$

$$(4) \quad \|\mathbf{x}^{(k)} - \mathbf{x}_*\| \leq \frac{q^k}{1-q} \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|$$

# 收敛速度

- 迭代法的收敛速度

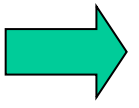
第  $k$  步的误差:  $\boldsymbol{\varepsilon}^{(k)} \triangleq \boldsymbol{x}^{(k)} - \boldsymbol{x}_* = \boldsymbol{B}^k \boldsymbol{\varepsilon}^{(0)}$

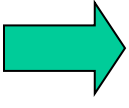

$$\frac{\|\boldsymbol{\varepsilon}^{(k)}\|}{\|\boldsymbol{\varepsilon}^{(0)}\|} \leq \|\boldsymbol{B}^k\|$$

平均每次迭代后的误差压缩率约为:  $\|\boldsymbol{B}^k\|^{\frac{1}{k}}$

- 若要求  $k$  步迭代后上述误差比值不超过  $\sigma$ , 则

$$\|\boldsymbol{B}^k\| \leq \sigma \Rightarrow \|\boldsymbol{B}^k\|^{\frac{1}{k}} \leq \sigma^{\frac{1}{k}}$$


$$\ln \|\boldsymbol{B}^k\|^{\frac{1}{k}} \leq \frac{1}{k} \ln \sigma$$


$$k \geq \frac{-\ln \sigma}{-\ln \|\boldsymbol{B}^k\|^{\frac{1}{k}}}$$

# 收敛速度

- 迭代法的收敛速度

**定义：** 迭代法  $x^{(k+1)} = Bx^{(k)} + f$  的平均收敛速度定义为

$$R_k(B) = -\ln \left( \|B^k\|^{\frac{1}{k}} \right)$$

渐进收敛速度为

$$R(B) = \lim_{k \rightarrow \infty} R_k(B) = -\ln \rho(B) = \ln \frac{1}{\rho(B)}$$

- $\rho(B)$  越小，迭代收敛越快



## ■ 几类基本迭代法

- Jacobi 迭代法
- Gauss-Seidel 迭代法
- SOR（超松弛）迭代法
- 迭代法收敛性分析

## 6.2.1 Jacobi 迭代方法

- 对应的矩阵分裂
- 迭代格式（矩阵形式，分量形式）

# Jacobi 迭代

- Jacobi 迭代法

考虑线性方程组  $Ax = b$

其中  $A=[a_{ij}]_{n \times n}$  非奇异, 且对角线元素全不为 0

- 将  $A$  分裂成  $A = D - L - U$ , 其中

$$D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$$

$$L = \begin{bmatrix} 0 & 0 & \cdots & 0 \\ -a_{21} & 0 & \cdots & 0 \\ \vdots & \ddots & \ddots & \vdots \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix}, \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & 0 & \ddots & \vdots \\ \vdots & \vdots & \ddots & -a_{n-1,n} \\ 0 & 0 & \cdots & 0 \end{bmatrix}$$

# Jacobi 迭代法

取  $M = D$ ,  $N = L + U$ , 可得 雅可比 (Jacobi) 迭代方法

$$\mathbf{x}^{(k+1)} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{b} \quad k = 0, 1, 2, \dots$$

● 迭代矩阵记为:  $\mathbf{J} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})$

● 分量形式: 
$$x_i^{(k+1)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right) / a_{ii}$$
$$i = 1, 2, \dots, n, \quad k = 0, 1, 2, \dots$$

$$\begin{cases} x_1^{(k+1)} = (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)})/a_{11} \\ x_2^{(k+1)} = (b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)})/a_{22} \\ \vdots \\ x_n^{(k+1)} = (b_n - a_{n1}x_1^{(k)} - a_{n2}x_2^{(k)} - \cdots - a_{n,n-1}x_{n-1}^{(k)})/a_{nn} \end{cases}$$

● 在计算  $x_i^{(k+1)}$  时，如果用  $x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}$  代替  $x_1^{(k)}, \dots, x_{i-1}^{(k)}$ ，  
则可能会得到更好的收敛效果。

$$\begin{cases} x_1^{(k+1)} = (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)})/a_{11} \\ x_2^{(k+1)} = (b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)})/a_{22} \\ \vdots \\ x_n^{(k+1)} = (b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \cdots - a_{n,n-1}x_{n-1}^{(k+1)})/a_{nn} \end{cases}$$

例

$$\begin{cases} 9x_1 - x_2 - x_3 = 7 \\ -x_1 + 10x_2 - x_3 = 8 \\ -x_1 - x_2 + 15x_3 = 13 \end{cases}$$

特点: 系数矩阵主  
对角元均不为零

$$\longleftrightarrow \begin{cases} x_1 = (7 + x_2 + x_3) / 9 \\ x_2 = (8 + x_1 + x_3) / 10 \\ x_3 = (13 + x_1 + x_2) / 15 \end{cases} \quad \text{取 } X^{(0)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

计算格式  $X^{(1)} = B X^{(0)} + f$

$$\begin{bmatrix} x_1^{(1)} \\ x_2^{(1)} \\ x_3^{(1)} \end{bmatrix} = \begin{bmatrix} 0 & 1/9 & 1/9 \\ 1/10 & 0 & 1/10 \\ 1/15 & 1/15 & 0 \end{bmatrix} \begin{bmatrix} x_1^{(0)} \\ x_2^{(0)} \\ x_3^{(0)} \end{bmatrix} + \begin{bmatrix} 7/9 \\ 8/10 \\ 13/15 \end{bmatrix}$$

**计算格式:  $X^{(k+1)}=BX^{(k)}+f$**

$X^{(0)}$	$X^{(1)}$	$X^{(2)}$	$X^{(3)}$	$X^{(4)}$	.....
<b>0</b>	<b>0.7778</b>	<b>0.9630</b>	<b>0.9929</b>	<b>0.9987</b>	
<b>0</b>	<b>0.8000</b>	<b>0.9644</b>	<b>0.9935</b>	<b>0.9988</b>	
<b>0</b>	<b>0.8667</b>	<b>0.9778</b>	<b>0.9952</b>	<b>0.9991</b>	

**准确解**    **→**     $X^*$   
**1.0000**  
**1.0000**  
**1.0000**

## 6.2.2 Gauss-Seidel 迭代方法

- 对应的矩阵分裂
- 迭代格式（矩阵形式，分量形式）



# Gauss-Seidel 迭代

写成矩阵形式:

$$\mathbf{x}^{(k+1)} = \mathbf{D}^{-1} \left( \mathbf{b} + \mathbf{L}\mathbf{x}^{(k+1)} + \mathbf{U}\mathbf{x}^{(k)} \right)$$

可得

$$\mathbf{x}^{(k+1)} = \left( \mathbf{D} - \mathbf{L} \right)^{-1} \mathbf{U}\mathbf{x}^{(k)} + \left( \mathbf{D} - \mathbf{L} \right)^{-1} \mathbf{b}$$

$$k = 0, 1, 2, \dots$$

此迭代方法称为 **高斯-塞德尔 (Gauss-Seidel)** 迭代法

- 迭代矩阵记为:  $\mathbf{G} = \left( \mathbf{D} - \mathbf{L} \right)^{-1} \mathbf{U}$

$$\text{例} \quad \begin{cases} 9x_1 - x_2 - x_3 = 7 \\ -x_1 + 10x_2 - x_3 = 8 \\ -x_1 - x_2 + 15x_3 = 13 \end{cases} \Leftrightarrow \begin{cases} x_1 = (7 + x_2 + x_3) / 9 \\ x_2 = (8 + x_1 + x_3) / 10 \\ x_3 = (13 + x_1 + x_2) / 15 \end{cases}$$

$$x_1^{(k+1)} = (7 + x_2^{(k)} + x_3^{(k)}) / 9$$

$$x_2^{(k+1)} = (8 + \textcolor{red}{x}_1^{(k+1)} + x_3^{(k)}) / 10$$

$$x_3^{(k+1)} = (13 + \textcolor{red}{x}_1^{(k+1)} + \textcolor{red}{x}_2^{(k+1)}) / 15$$

$$\begin{bmatrix} x_1^{(0)} \\ x_2^{(0)} \\ x_3^{(0)} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 0 & 0 \\ -1/10 & 1 & 0 \\ -1/15 & -1/15 & 1 \end{bmatrix} \begin{bmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \\ x_3^{(k+1)} \end{bmatrix} = \begin{bmatrix} 0 & 1/9 & 1/9 \\ 0 & 0 & 1/10 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1^{(k)} \\ x_2^{(k)} \\ x_3^{(k)} \end{bmatrix} + \begin{bmatrix} 7/9 \\ 8/10 \\ 13/15 \end{bmatrix}$$

## 迭代法解线性方程组

$$\begin{cases} 9x_1 - x_2 - x_3 = 7 \\ -x_1 + 10x_2 - x_3 = 8 \\ -x_1 - x_2 + 15x_3 = 13 \end{cases}$$

### 雅可比迭代法实验数据

0.7778	0.8000	0.8667
0.9630	0.9644	0.9719
0.9929	0.9935	0.9952
0.9987	0.9988	0.9991
0.9998	0.9998	0.9998
1.0000	1.0000	1.0000

### 赛德尔迭代法实验数据

0.7778	0.8778	0.9770
0.9839	0.9961	0.9987
0.9994	0.9998	0.9999
1.0000	1.0000	1.0000
1.0000	1.0000	1.0000

## 6.3.1 SOR 迭代

### G-S 迭代法的分量形式

$$\begin{aligned}x_i^{(k+1)} &= \left( b_i - a_{i1}x_1^{(k+1)} - \cdots - a_{i,i-1}x_{i-1}^{(k+1)} - a_{i,i+1}x_{i+1}^{(k)} - \cdots - a_{in}x_n^{(k)} \right) / a_{ii} \\&= x_i^{(k)} + \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i}^n a_{ij}x_j^{(k)} \right) / a_{ii}\end{aligned}$$

- 为了得到更好的收敛效果，可在修正项前乘以一个 **松弛因子**  $\omega$ ，于是可得迭代格式

$$x_i^{(k+1)} = x_i^{(k)} + \omega \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i}^n a_{ij}x_j^{(k)} \right) / a_{ii}$$

## 6.3.1 SOR 迭代方法

- 迭代格式（矩阵形式，分量形式）
- 迭代矩阵

# SOR 迭代

写成矩阵形式:

$$x^{(k+1)} = x^{(k)} + \omega D^{-1} \left( b + Lx^{(k+1)} + Ux^{(k)} - Dx^{(k)} \right)$$

可得

$$x^{(k+1)} = (D - \omega L)^{-1} [(1 - \omega)D + \omega U] x^{(k)} + \omega (D - \omega L)^{-1} b$$

—— **SOR (Successive Over-Relaxation)** 迭代方法

● 迭代矩阵记为:  $L_{\omega} = (D - \omega L)^{-1} [(1 - \omega)D + U]$

- SOR 的优点: 通过选取合适的  $\omega$ , 可获得更快的收敛速度
- SOR 的缺点: 最优参数  $\omega$  的选取比较困难

successive overrelaxation

Prof. David M. Young

1954 美国数学科学学报



Iterative methods for solving partial differential equations of elliptic

**定理** 若  $A$  是对称正定矩阵, 则当  $0 < \omega < 2$  时

SOR 迭代法解方程组  $Ax = b$  是收敛的

最佳松弛因子选取 
$$\omega = \frac{2}{1 + \sqrt{1 - \rho(B_J)^2}}$$

$\rho(B_J)$  为 Jacobi 迭代谱半径

● Jacobi 迭代  $M = D, N = L + U$

$$\mathbf{x}^{(k+1)} = D^{-1}(L + U)\mathbf{x}^{(k)} + D^{-1}\mathbf{b}$$

$$x_i^{(k+1)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right) / a_{ii}$$

---

● G-S 迭代  $M = D - L, N = U$

$$\mathbf{x}^{(k+1)} = (D - L)^{-1}U\mathbf{x}^{(k)} + (D - L)^{-1}\mathbf{b}$$

$$x_i^{(k+1)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right) / a_{ii}$$

---

● SOR 迭代  $M = \frac{1}{\omega}(D - \omega L), N = \frac{1}{\omega}[(1 - \omega)D + \omega U]$

$$\mathbf{x}^{(k+1)} = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]\mathbf{x}^{(k)} + \omega(D - \omega L)^{-1}\mathbf{b}$$

$$x_i^{(k+1)} = x_i^{(k)} + \omega \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i}^n a_{ij}x_j^{(k)} \right) / a_{ii}$$



# 举例

**例：**分别用 Jacobi、G-S、SOR 迭代解线性方程组

$$\begin{bmatrix} 2 & -1 & 0 \\ -1 & 3 & -1 \\ 0 & -1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 8 \\ -5 \end{bmatrix}$$

$$x_* = \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix}$$

取初始向量  $x^{(0)} = [0, 0, 0]^T$ ，迭代过程中小数点后保留 4 位。

**解：**

**Jacobi 迭代：**

$$\begin{cases} x_1^{(k+1)} = (1 + x_2^{(k)})/2 \\ x_2^{(k+1)} = (8 + x_1^{(k)} + x_3^{(k)})/3 \\ x_3^{(k+1)} = (-5 + x_2^{(k)})/2 \end{cases}$$

迭代可得：

$$\begin{aligned} x^{(1)} &= [0.5000, 2.6667, -2.5000]^T \\ &\vdots \\ x^{(21)} &= [2.0000, 3.0000, -1.0000]^T \end{aligned}$$

# 举例

G-S 迭代:

$$\begin{cases} x_1^{(k+1)} = (1 + x_2^{(k)})/2 \\ x_2^{(k+1)} = (8 + x_1^{(k+1)} + x_3^{(k)})/3 \\ x_3^{(k+1)} = (-5 + x_2^{(k+1)})/2 \end{cases}$$

迭代可得:

$$x^{(1)} = [ 0.5000, 2.8333, -1.0833 ]^T$$

$\vdots$

$$x^{(9)} = [ 2.0000, 3.0000, -1.0000 ]^T$$

# 举例

**SOR 迭代:**

$$\begin{cases} x_1^{(k+1)} = x_1^{(k)} + \omega(1 - 2x_1^{(k)} + x_2^{(k)})/2 \\ x_2^{(k+1)} = x_2^{(k)} + \omega(8 + x_1^{(k+1)} - 3x_2^{(k)} + x_3^{(k)})/3 \\ x_3^{(k+1)} = x_3^{(k)} + \omega(-5 + x_2^{(k+1)} - 2x_3^{(k)})/2 \end{cases}$$

取  $\omega = 1.1$ , 迭代可得

$$x^{(1)} = [ 0.5500, 3.1350, -1.0257 ]^T$$

$\vdots$

$$x^{(7)} = [ 2.0000, 3.0000, -1.0000 ]^T$$

如何确定 SOR 的最优松弛因子是一件**非常困难**的事

## 6.2.3 迭代方法的收敛性

- Jacobi 迭代收敛的**充要**条件  $\rho(J) < 1$
  - G-S 迭代收敛的**充要**条件  $\rho(G) < 1$
  - SOR 迭代收敛的**充要**条件  $\rho(L_\omega) < 1$
  - Jacobi 迭代收敛的**充分**条件  $\|J\| < 1$
  - G-S 迭代收敛的**充分**条件  $\|G\| < 1$
  - SOR 迭代收敛的**充分**条件  $\|L_\omega\| < 1$
- 
- 对角占优、不可约矩阵
  - 对称正定矩阵

# 对角占优矩阵

定义：设  $A \in \mathbb{R}^{n \times n}$ ，若

$$|a_{ii}| \geq \sum_{j=1, j \neq i}^n |a_{ij}| \quad (i = 1, 2, \dots, n)$$

且至少有一个不等式严格成立，则称  $A$  为 **弱对角占优**；  
若所有不等式都严格成立，则称  $A$  为 **严格对角占优**。

**命题：** 如果 $A$ 是严格主对角占优矩阵, 则  $\det(A) \neq 0$ .

证: 用反证法。设 $\det(A) = 0$ , 则齐次方程组 $Ax=0$ 有非零解  $u = [u_1, u_2, \cdots, u_n]^T$ .

设  $\|u\|_\infty = |u_k|$  考虑 $Au=0$ 的第 $k$ 个等式

$$a_{k1}u_1 + \cdots + a_{kk}u_k + \cdots + a_{kn}u_n = 0 \quad \rightarrow$$

$$|a_{kk}| \cdot |u_k| = \left| \sum_{\substack{j=1 \\ j \neq k}}^n a_{kj}u_j \right| \leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}u_j| \leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}| \cdot |u_k|$$

两边约去  $|u_k|$ , 得  $|a_{kk}| \leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}|$

这与主对角占优矛盾, 故 $\det(A) \neq 0$ 。

# 可约矩阵与不可约矩阵

**定义：** 设  $A \in \mathbb{R}^{n \times n}$ ，若存在置换矩阵  $P$  使得

$$P^T A P = \begin{bmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{bmatrix}, \quad \begin{matrix} A_{11} \in \mathbb{R}^{r \times r}, & A_{22} \in \mathbb{R}^{(n-r) \times (n-r)} \\ 1 \leq r \leq n-1 \end{matrix}$$

则称  $A$  为 **可约矩阵**；否则称为 **不可约矩阵**。

- 如果  $A$  是可约矩阵，则方程组  $Ax = b$  等价于

$$\begin{matrix} (P^T A P) & (P^T x) & = & P^T b \\ \downarrow & \downarrow & & \\ y & f & & \end{matrix} \quad \longleftrightarrow \quad \begin{cases} A_{11}y_1 + A_{12}y_2 = f_1 \\ A_{22}y_2 = f_2 \end{cases}$$

即可以把原方程组化成两个**低阶**的方程组来处理。

# 可约矩阵的几个简单判别方法

**性质：** 设  $A \in \mathbb{R}^{n \times n}$ ，若  $A$  的所有元素都非零，则  $A$  不可约。

**性质：** 设  $A \in \mathbb{R}^{n \times n}$ ，且  $n \geq 2$ 。若  $A$  可约，则  $A$  的零元素个数大于等于  $n-1$ 。

**性质：** 设  $A \in \mathbb{R}^{n \times n}$  是三对角矩阵，且三条对角线元素均非零，则  $A$  不可约。

$$A = \begin{bmatrix} b_1 & c_1 & & & \\ a_1 & \ddots & \ddots & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & c_{n-1} & \\ & & & b_n & \end{bmatrix}$$

**思考：** 如  $A$  是三对角矩阵，上、下次对角线元素均非零，则  $A$  是不是不可约？



# Jacobi、G-S 收敛性

## ■ 对角占优情形

**定理：** 若  $A$  严格对角占优或不可约弱对角占优，则  $A$  非奇异

**定理：** 若  $A$  严格对角占优或不可约弱对角占优，则 Jacobi 迭代和 G-S 迭代均收敛

定义  $A=(a_{ij})_{n \times n}$ , 如果  $|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$

则称  $A$  为 (行) 严格对角占优阵.

**定理** 若  $Ax=b$  的系数矩阵  $A$  是 (行) 严格对角占优矩阵, 则 Jacobi 迭代收敛.

证: 由于矩阵  $A$  严格对角占优

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \quad \Rightarrow \quad \frac{1}{|a_{ii}|} \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| < 1$$

而  $B_J = D^{-1}(D-A) = \begin{bmatrix} 0 & -a_{12}/a_{11} & \cdots & -a_{1n}/a_{11} \\ -a_{21}/a_{22} & 0 & \cdots & -a_{2n}/a_{22} \\ \cdots & \cdots & \cdots & \cdots \\ -a_{n1}/a_{nn} & -a_{n2}/a_{nn} & \cdots & 0 \end{bmatrix}$

故Jacobi迭代矩阵 $B_J = D^{-1}(D - A)$  第  $i$  行绝对值求和

$$\frac{1}{|a_{ii}|} \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| < 1 \quad (i = 1, 2, \dots, n)$$

所以  $\|B_J\|_{\infty} = \max_{1 \leq i \leq n} \left\{ \frac{1}{|a_{ii}|} \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \right\} < 1$

故Jacobi迭代  $X^{(k+1)} = B_J X^{(k)} + f$  收敛.

**定理** 若  $A$  是（行）严格主对角占优矩阵，则求解方程组  $Ax=b$  的高斯-赛德尔迭代法收敛。

证：高斯-赛德尔迭代矩阵为  $(D-L)^{-1}U$ ，该矩阵的特征方程为

$$|\lambda(D-L) - U| = 0$$

行列式对应的矩阵为

$$C(\lambda) = \begin{bmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n} \\ \lambda a_{21} & \lambda a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda a_{n1} & \lambda a_{n2} & \cdots & \lambda a_{nn} \end{bmatrix}$$

当  $|\lambda| \geq 1$  时，利用  $A$  矩阵的主对角占优性质，得

$$|\lambda a_{ii}| = |\lambda| \times |a_{ii}| > |\lambda| \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| = \sum_{\substack{j=1 \\ j \neq i}}^n |\lambda| \times |a_{ij}| \geq \sum_{j=1}^{i-1} |\lambda a_{ij}| + \sum_{j=i+1}^n |a_{ij}|$$

故 $C(\lambda)$ 是严格主对角占优矩阵, 故矩阵的行列式 $|C(\lambda)|$ 不为零, 所以满足 $|\lambda| \geq 1$ 的 $\lambda$ 不是特征方程

$$|C(\lambda)| = |\lambda(D - L) - U| = 0$$

的根。当 $A$ 是严格主对角占优矩阵时,  $(D - L)^{-1}U$ 的特征值必然满足:  $|\lambda| < 1$ , 从而高斯-赛德尔迭代矩阵谱半径小于1, 迭代法收敛。

# Jacobi、G-S 收敛性

## ■ 对称正定情形

**定理：** 设  $A$  对称且  $D$  正定，则 Jacobi 迭代收敛的**充要条件**是  $A$  和  $2D-A$  都正定。

**定理：** 设  $A$  对称且  $D$  正定，则 G-S 迭代收敛的**充要条件**是  $A$  正定。

# SOR 收敛性

- SOR 收敛的必要条件

**定理：** 若 SOR 迭代收敛，则  $0 < \omega < 2$ 。

- SOR 收敛的充分条件

**定理：** 若  $A$  对称正定，且  $0 < \omega < 2$ ，则 SOR 迭代收敛。

**定理：** 若  $A$  严格对角占优或不可约弱对角占优，且  $0 < \omega \leq 1$ ，则 SOR 迭代收敛。

# 收敛性小结

$A$  对称且对角线元素为正, 则

(1) Jacobi 迭代收敛  $\longleftrightarrow A$  正定且  $2D-A$  正定

(2) G-S 迭代收敛  $\longleftrightarrow A$  正定

$A$  对称正定, 则 SOR 迭代收敛  $\longleftrightarrow 0 < \omega < 2$

$A$  严格对角占优或不可约弱对角占优

$\longrightarrow$  Jacobi 和 Gauss-Seidel 迭代收敛

$A$  严格对角占优或不可约弱对角占优且  $0 < \omega \leq 1$

$\longrightarrow$  SOR 迭代收敛



# 举例

**例：** 设  $A = \begin{bmatrix} 1 & a & a \\ a & 1 & a \\ a & a & 1 \end{bmatrix}$ ，给出 Jacobi 和 G-S 收敛的充要条件


**解：** A 对称，且对角线元素均大于 0，故

(1) Jacobi 收敛的充要条件是 A 和  $2D-A$  均正定

(2) G-S 收敛的充要条件是 A 正定

$$\begin{aligned} A \text{ 正定} &\iff D_1 = 1 > 0, D_2 = 1 - a^2 > 0, D_3 = (1 - a)^2(1 + 2a) > 0 \\ &\iff -0.5 < a < 1 \end{aligned}$$

$$\begin{aligned} 2D-A \text{ 正定} &\iff D_1 = 1 > 0, D_2 = 1 - a^2 > 0, D_3 = (1 + a)^2(1 - 2a) > 0 \\ &\iff -0.5 < a < 0.5 \end{aligned}$$



Jacobi 收敛的充要条件是：  $-0.5 < a < 0.5$


G-S 收敛的充要条件是：  $-0.5 < a < 1$

# 举例

解法二： Jacobi 的迭代矩阵为  $J = \begin{bmatrix} 0 & -a & -a \\ -a & 0 & -a \\ -a & -a & 0 \end{bmatrix}$

设  $\lambda$  是  $J$  的特征值，则由  $\det(\lambda I - J) = 0$  可得

$$(\lambda - a)^2 (\lambda + 2a) = 0$$



Jacobi 收敛的充要条件是  $\rho(J) < 1 \Leftrightarrow |\lambda| < 1$ ,  
即  $-0.5 < a < 0.5$

# 补：算法的实施

停机准则：
$$\frac{\|b - Ax^{(k)}\|}{\|b - Ax^{(0)}\|} < \varepsilon$$

算法：Jacobi

(G-S 和 SOR 的实施类似)

- (1) 给定初值  $x^{(0)}$  和精度要求  $\varepsilon$
- (2) 计算  $r^{(0)} = b - Ax^{(0)}$
- (3) 对  $k = 0, 1, 2, \dots$ , 计算

$$x_i^{(k+1)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right) / a_{ii}, \quad i = 1, 2, \dots, n$$

若  $\frac{\|b - Ax^{(k)}\|}{\|r^{(0)}\|} < \varepsilon$ , 则输出  $x_* \approx x^{(k+1)}$ , 停止计算。


## 6.4 CG 方法

- 线性方程组与极值问题
- 最速下降法
- CG 方法（共轭梯度法）

## 6.4.1 线性方程组与极值问题

设  $A$  对称正定


**定理：** 向量  $x_* \in R^n$  是  $\varphi(x)$  的极小值当且仅当  
 $\varphi'(x_*)=0$  且 Hesse 矩阵  $H_{\varphi}(x_*)$  对称正定



$Ax = b$  的解  $\longleftrightarrow \varphi(x) \triangleq \frac{1}{2}(Ax, x) - (b, x)$  的最小值

## 6.4.2 梯度下降法

求解线性方程组  $Ax = b$



求  $\varphi(x)$  的最小值点(极小值点)

### 基本思想:

- (1) 选取一个初始向量  $x^{(0)}$
- (2) 确定一个下降方向  $p^{(0)}$ , 从  $x^{(0)}$  出发, 沿方向  $p^{(0)}$  找极小点  $x^{(1)}$
- (3) 以  $x^{(1)}$  点为新的出发点, 确定一个新的下降方向  $p^{(1)}$ , 从  $x^{(1)}$  出发, 沿  $p^{(1)}$  找极小点  $x^{(2)}$
- (4) 以此类推, 不断寻找新的点  $x^{(k)}$ , 直到找出最小值点  $x_*$

# 两个基本问题

**问题一：如何确定 下降方向？**

**问题二：如何确定 步长？**

# 最速下降法

## 基本思想:

任取一个迭代初始向量  $x^{(0)}$ , 构造迭代序列  $x^{(0)}, x^{(1)}, x^{(2)}, \dots$ , 使得  $\varphi(x^{(0)}) > \varphi(x^{(1)}) > \varphi(x^{(2)}) > \dots$ , 且每一步都以最快的速度下降到  $\varphi(x)$  的极小值。

## 具体作法:

设  $x^{(k)}$  已经求得, 计算  $x^{(k+1)}$ :  $\varphi(x)$  沿  $x^{(k)}$  处的最速下降方向, 即负梯度方向  $r^{(k)} = -(Ax^{(k)} - b)$  的最小值点, 即


$$\varphi(x^{(k+1)}) = \min_{\alpha \in R} \varphi(x^{(k)} + \alpha r^{(k)})$$



# 最速下降法

计算  $\alpha$  的值

$$\varphi(x^{(k)} + \alpha r^{(k)}) = \frac{\alpha^2}{2} (Ar^{(k)}, r^{(k)}) + \alpha (Ax^{(k)} - b, r^{(k)}) + \varphi(x^{(k)})$$



$$\alpha_k = \arg \min_{\alpha \in \mathbb{R}} \varphi(x^{(k)} + \alpha r^{(k)}) = -\frac{(Ax^{(k)} - b, r^{(k)})}{(Ar^{(k)}, r^{(k)})} = \frac{(r^{(k)}, r^{(k)})}{(Ar^{(k)}, r^{(k)})}$$

# 最速下降法

算法：（最速下降法）

(1) 给定初值  $x^{(0)}$  和精度要求  $\varepsilon$

(2) 计算  $r^{(0)} = b - Ax^{(0)}$

(3) 对  $k = 0, 1, 2, \dots$ ，计算

$$\alpha_k = \left( r^{(k)}, r^{(k)} \right) / \left( Ar^{(k)}, r^{(k)} \right)$$

$$x^{(k+1)} = x^{(k)} + \alpha_k r^{(k)}$$

$$r^{(k+1)} = b - Ax^{(k+1)} = r^{(k)} - \alpha_k Ar^{(k)}$$

若  $\frac{\|r^{(k+1)}\|}{\|r^{(0)}\|} < \varepsilon$ ，则输出  $x_* \approx x^{(k+1)}$ ，停止计算。

# 最速下降法的收敛性

**定理：** 设  $A$  对称正定，其特征值为  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0$   
则由最速下降法产生的序列满足

$$\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}_* = A^{-1}\mathbf{b}$$

且有

$$\|\mathbf{x}^{(k)} - \mathbf{x}_*\|_A \leq \left( \frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^k \|\mathbf{x}^{(0)} - \mathbf{x}_*\|_A$$

**缺点：**

- (1) 若  $\lambda_1 \gg \lambda_n$ ，则收敛很慢，并可能出现不稳定现象 (舍入误差)
- (2) 每次的下降方向为局部下降最快，并非全局最快


# 举例


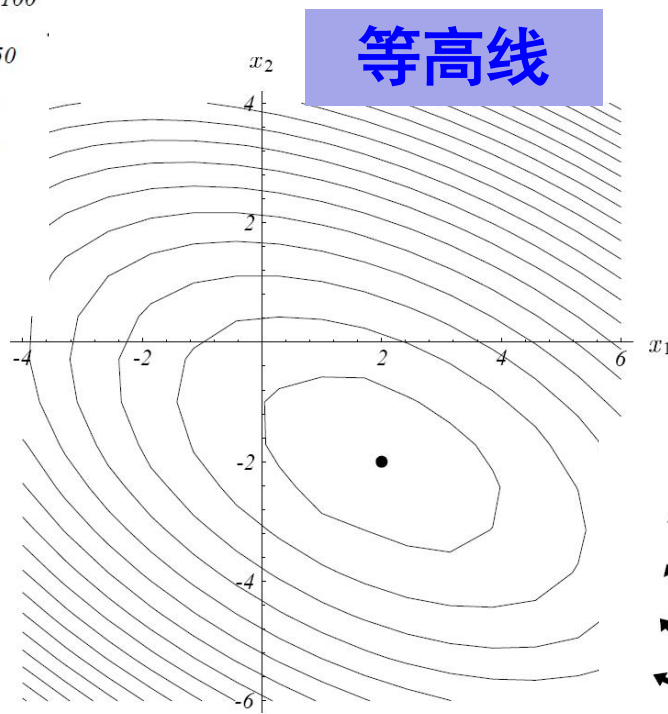

$$\begin{cases} 3x_1 + 2x_2 = 2 \\ 2x_1 + 6x_2 = -8 \end{cases}$$

$$A = \begin{bmatrix} 3 & 2 \\ 2 & 6 \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ -8 \end{bmatrix}, \quad x_* = A^{-1}b = \begin{bmatrix} 2 \\ -2 \end{bmatrix}$$

$$\varphi(x) = \frac{1}{2}x^T Ax - b^T x = \frac{3}{2}x_1^2 + 2x_1x_2 + 3x_2^2 - 2x_1 + 8x_2$$


# 举例





# 举例

最速下降法



# 共轭梯度法

## 出发点:

在确定  $x^{(k+1)}$  时，不沿负梯度方向取极小，而是寻找一个更好的方向  $p^{(k)}$ ，使得  $\varphi(x)$  下降得更快！

**定义：** 设  $A$  对称正定，若  $(x, Ay) = 0$ ，则称  $x, y$  关于  $A$  正交 ( $A$ -正交) 或  $A$ -共轭，若  $z_1, z_2, \dots, z_n$  相互  $A$ -共轭，则称  $z_1, z_2, \dots, z_n$  构成  $A$ -正交向量组或  $A$ -共轭向量组。



# 共轭梯度法

## 具体作法:

令  $p^{(0)} = r^{(0)}$ ，设  $x^{(k)}$  已经求得，则  $x^{(k+1)}$  由下面的公式确定：

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$$

其中

$$p^{(k)} = r^{(k)} + \beta_{k-1} p^{(k-1)}$$

$$\beta_{k-1} = -\left(r^{(k)}, Ap^{(k-1)}\right) / \left(p^{(k-1)}, Ap^{(k-1)}\right)$$

$$\alpha_k = \left(r^{(k)}, p^{(k)}\right) / \left(p^{(k)}, Ap^{(k)}\right)$$

# 共轭梯度法

**定理：** 设  $A$  对称正定，则由 CG 算法产生的序列满足

(1) 当  $i \neq j$  时， $(r^{(i)}, r^{(j)}) = 0$ ，即  $r^{(0)}, r^{(1)}, r^{(2)}, \dots$  相互正交

(2) 当  $i \neq j$  时， $(p^{(i)}, Ap^{(j)}) = 0$ ，即  $p^{(0)}, p^{(1)}, p^{(2)}, \dots$  相互  $A$ -共轭

**参数的新计算公式：**

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(p^{(k)}, Ap^{(k)})}, \quad \beta_k = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})}$$

# 共轭梯度法

## 算法：（共轭梯度法）

- (1) 给定初值  $x^{(0)}$  和精度要求  $\varepsilon$
- (2) 计算  $r^{(0)} = b - Ax^{(0)}$ ，令  $p^{(0)} = r^{(0)}$
- (3) 对  $k = 0, 1, 2, \dots$ ，计算

$$\alpha_k = \left( r^{(k)}, r^{(k)} \right) / \left( Ap^{(k)}, p^{(k)} \right)$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$$

$$r^{(k+1)} = b - Ax^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)}$$

若  $\|r^{(k+1)}\| / \|r^{(0)}\| < \varepsilon$ ，则输出  $x_* = x^{(k+1)}$ ，停止计算。

$$\beta_k = \left( r^{(k+1)}, r^{(k+1)} \right) / \left( r^{(k)}, r^{(k)} \right)$$

$$p^{(k+1)} = r^{(k+1)} + \beta_k p^{(k)}$$

# 共轭梯度法的收敛性

**定理：** 设  $A$  对称正定，则共轭梯度法至多  $n$  步就能找到精确解。

**定理：** 设  $A$  对称正定， $\mathbf{x}_*$  为精确解， $\mathbf{x}^{(k)}$  为共轭梯度法的数值解，则有

$$\|\mathbf{x}^{(k)} - \mathbf{x}_*\|_A \leq 2 \left( \frac{\sqrt{K} - 1}{\sqrt{K} + 1} \right)^k \|\mathbf{x}^{(0)} - \mathbf{x}_*\|_A$$

其中  $K = \text{cond}(A)_2 = \|A\|_2 \|A^{-1}\|_2$

# 总结

- **Jacobi迭代与Seidel迭代**
- **超松弛(SOR)迭代算法**
- **迭代矩阵与收敛性分析**
- **共轭梯度**